

Modelo *Surrogate* para Avaliação da Aptidão de Equipes: Construção, Formalização e Validação

Felipe Oliveira Miranda Cunha

September 11, 2026

1 Construção do Surrogate Model

Para reduzir o custo computacional da função de avaliação do Algoritmo Genético (AG), foi construído um *surrogate model* para substituir a Rede Bayesiana (BN). Embora interpretável, a BN exige inferência probabilística a cada avaliação de equipe, o que se torna custoso quando o AG realiza milhares de chamadas à função de avaliação ao longo das gerações. O surrogate foi, portanto, definido como um avaliador analítico e de baixo custo, capaz de imitar a BN utilizando as mesmas evidências de entrada já disponíveis no pipeline de avaliação.

O *surrogate* utiliza as mesmas evidências técnicas e colaborativas empregadas pela BN. A Aptidão Técnica (*AT*) é calculada a partir dos requisitos de domínio, ecossistema e linguagem, organizados segundo as prioridades *Must-have*, *Should-have* e *Could-have*. O cálculo combina a avaliação intra-prioridade (Situação 2) com a agregação interprioridades (Situação 1).

Na versão refinada, os requisitos *Must-have* permanecem obrigatórios e sua redundância é representada pelas proporções cobertas por pelo menos dois e três integrantes. As contribuições de *Should-have* e *Could-have* são calculadas independentemente, ambas condicionadas à cobertura de *Must-have*. Consequentemente, o aumento da cobertura de *Should-have* não reduz a contribuição de *Could-have*, e vice-versa.

A Aptidão Colaborativa (*AC*) é derivada da distribuição de compatibilidade entre os pares de desenvolvedores nas cinco faixas ($p_{VL}, p_L, p_M, p_H, p_{VH}$). Diferentemente da BN, que recebe um rótulo ordinal, o *surrogate* opera sobre essas proporções, calcula seu valor esperado e, na versão refinada, aplica uma compressão linear em torno do ponto neutro 0,5. Essa transformação preserva a ordenação da compatibilidade colaborativa, mas reduz sua amplitude operacional antes da combinação com *AT*.

A estrutura funcional do surrogate foi inspirada diretamente pelas funções de agregação utilizadas na BN. Para a aptidão técnica, a BN emprega uma média ponderada (WMEAN) sobre os nós Dom, Eco e Ling, o que o surrogate replica analiticamente com os mesmos pesos. Para a aptidão global da equipe, a BN emprega a função MIXMINMAX, que combina o mínimo e o máximo entre *AT* e *AC* com pesos assimétricos, impondo um forte efeito de gargalo pelo atributo mais fraco. O surrogate adota a mesma estrutura funcional, parametrizando os pesos do mínimo e do máximo como variáveis a calibrar. Como a estrutura do surrogate é analiticamente mais simples que a inferência probabilística da BN, seus parâmetros foram ajustados empiricamente usando a própria BN como *teacher model*, com o objetivo de maximizar a fidelidade da aproximação.

1.1 Formulação matemática do surrogate




Figure 1: Arquitetura do surrogate model. Os escores técnicos (Dom , Eco , $Ling$) são combinados via WMEAN em AT_{sur} ; os valores de compatibilidade entre os $\binom{4}{2} = 6$ pares de desenvolvedores são agregados em AC_{original} pelo valor esperado $\sum_s c_s \cdot p_s$ sobre os centróides ordinais das faixas $\{VL, L, M, H, VH\}$. Em seguida, a transformação $AC_{\text{cont}} = 0,5 + 0,5(AC_{\text{original}} - 0,5)$ comprime o escore colaborativo em torno do ponto neutro 0,5 antes de sua combinação com AT_{sur} . A função MIXMINMAX combina os dois resumos com efeito de gargalo ($w_{\min} = 5$, $w_{\max} = 1$), produzindo o escalar $AE_{\text{sur}} \in [0, 1]$, utilizado diretamente como fitness pelo Algoritmo Genético. O bloco tracejado à direita — conversão para distribuição de probabilidade via Gaussiana com $\sigma_{AE} = 0,15$ — é ativado apenas para compatibilidade de interface com os módulos de relatório do TeamPlus, que consomem o mesmo formato de saída da Rede Bayesiana.

(1) Escores técnicos por dimensão

Seja $\delta \in \{Dom, Eco, Ling\}$ uma dimensão técnica e sejam cov_M^δ , cov_S^δ e cov_C^δ as proporções de requisitos *Must-have*, *Should-have* e *Could-have* cobertos pela equipe. Para os requisitos obrigatórios, $\text{red}_{r,M}^\delta$ representa a proporção coberta por pelo menos r integrantes.

Quando duas ou mais prioridades estão ativas, o escore bruto refinado da dimensão é:

$$v^\delta = b_1 + w_{\text{covM}} \text{cov}_M^\delta + w_{\text{red2M}} \text{red}_{2,M}^\delta + w_{\text{red3M}} \text{red}_{3,M}^\delta + w_{\text{red4M}} \text{red}_{4,M}^\delta + w_{\text{should}} \left(\text{cov}_M^\delta \text{cov}_S^\delta \right) + w_{\text{could}} \left(\text{cov}_M^\delta \text{cov}_C^\delta \right). \quad (1)$$

Os parâmetros empregados são:

$$b_1 = 0, \quad w_{\text{covM}} = 0, \quad w_{\text{red2M}} = 0,4120879121,$$

$$w_{\text{red3M}} = 0,2582417582, \quad w_{\text{red4M}} = 0,$$

$$w_{\text{should}} = w_{\text{could}} = 0,2307692308.$$

O termo $\text{red}_{4,M}^\delta$ é mantido na formulação para preservar a rastreabilidade do modelo calibrado, mas não altera o escore porque seu peso é zero. Assim, a redundância efetivamente considerada é a cobertura dos requisitos obrigatórios por pelo menos dois e três integrantes.

As contribuições de *Should-have* e *Could-have* são independentes. A cobertura de *Should-have* contribui por $\text{cov}_M^\delta \text{cov}_S^\delta$, enquanto a de *Could-have* contribui por $\text{cov}_M^\delta \text{cov}_C^\delta$. Portanto, aumentar uma dessas coberturas não reduz a contribuição da outra.

Quando a dimensão não possui requisitos *Must-have*, adota-se $\text{cov}_M^\delta = 1$ como valor neutro. Quando esses requisitos existem, o escore dimensional contínuo é:

$$\text{DIM}^\delta = \text{clamp}_{[0,1]} \left(v^\delta \max \left(0, 1, \text{cov}_M^\delta \right) \right). \quad (2)$$

Essa expressão permite calcular o escore técnico contínuo para fins de diagnóstico. Na utilização operacional pelo AG, aplica-se adicionalmente a política rígida *Hard-Must*: uma equipe somente é considerada viável quando cobre integralmente todos os requisitos *Must-have* do projeto. Equipes que não satisfazem essa condição não concorrem com as equipes viáveis.

(2) Aptidão técnica do surrogate AT_{sur}

Sejam $Dom, Eco, Ling \in [0, 1]$ escores contínuos, definimos a aptidão técnica surrogate como:

$$AT_{\text{sur}} = \frac{w_{\text{dom}} Dom + w_{\text{eco}} Eco + w_{\text{ling}} Ling}{w_{\text{dom}} + w_{\text{eco}} + w_{\text{ling}}}. \quad (3)$$

Onde:

- Dom representa o grau de atendimento aos requisitos de domínio;
- Eco representa o grau de atendimento aos requisitos de ecossistema/plataforma;
- $Ling$ representa o grau de atendimento aos requisitos de linguagens;
- $w_{\text{dom}}, w_{\text{eco}}, w_{\text{ling}}$ são os pesos da combinação técnica.

Os pesos do componente técnico espelham diretamente os pesos da função WMEAN calibrada no nó AT da BN:

$$w_{\text{dom}} = 3, \quad w_{\text{eco}} = 1, \quad w_{\text{ling}} = 5.$$

Assim, a forma instanciada do componente técnico ficou:

$$AT_{\text{sur}} = \frac{3 Dom + 1 Eco + 5 Ling}{3 + 1 + 5} = \frac{3 Dom + Eco + 5 Ling}{9}. \quad (4)$$

(3) Aptidão colaborativa contínua AC_{cont}

Considere uma equipe T e o conjunto de seus pares de desenvolvedores $P(T)$. Cada par (i, j) possui uma compatibilidade $PC_{ij} \in [0, 1]$, classificada nas faixas:

$$\begin{aligned} PC_{VL} : 0.0 &\leq PC_{ij} < 0.2, \\ PC_L : 0.2 &\leq PC_{ij} < 0.4, \\ PC_M : 0.4 &\leq PC_{ij} < 0.6, \\ PC_H : 0.6 &\leq PC_{ij} < 0.8, \\ PC_{VH} : 0.8 &\leq PC_{ij} \leq 1.0. \end{aligned}$$

Sejam $p_{VL}, p_L, p_M, p_H, p_{VH}$ as proporções de pares em cada faixa, com:

$$p_{VL} + p_L + p_M + p_H + p_{VH} = 1.$$

O escore colaborativo original corresponde ao valor esperado da distribuição:

$$AC_{\text{original}} = 0.1 p_{VL} + 0.3 p_L + 0.5 p_M + 0.7 p_H + 0.9 p_{VH}. \quad (5)$$

A análise posterior à primeira validação mostrou que a amplitude operacional de AC era maior do que a observada em AT. Como as duas dimensões são combinadas pela função MIXMINMAX, essa diferença poderia introduzir uma influência decorrente das escalas, além daquela definida pelos pesos da política decisória.

Na versão refinada, aplica-se uma compressão linear e simétrica em torno do ponto neutro 0,5:

$$AC_{\text{cont}} = 0.5 + \gamma (AC_{\text{original}} - 0.5), \quad \gamma = 0.5. \quad (6)$$

Equivalentemente:

$$AC_{\text{cont}} = 0.25 + 0.5 AC_{\text{original}}.$$

A transformação converte os centróides operacionais

$$(0.1, 0.3, 0.5, 0.7, 0.9)$$

em:

$$(0.3, 0.4, 0.5, 0.6, 0.7).$$

Ela preserva a ordenação, a simetria e o ponto neutro da escala, mas reduz pela metade as distâncias em relação a 0,5. A compressão não força AT e AC a apresentarem valores idênticos; apenas reduz a diferença entre suas amplitudes operacionais.

(4) Aptidão global da equipe AE_{sur}

Tendo AT_{sur} e AC_{cont} como resumos técnico e colaborativo, a aptidão global do *surrogate* mantém a função MIXMINMAX utilizada pela BN. O refinamento não alterou essa função nem seus pesos; alterou a forma de calcular os escores técnicos por prioridade e a escala colaborativa fornecida como entrada.

A aptidão global da versão refinada é:

$$AE_{\text{sur}}(T) = \frac{w_{\min} \min(AT_{\text{sur}}(T), AC_{\text{cont}}(T)) + w_{\max} \max(AT_{\text{sur}}(T), AC_{\text{cont}}(T))}{w_{\min} + w_{\max}}. \quad (7)$$

Os pesos permanecem:

$$w_{\min} = 5, \quad w_{\max} = 1.$$

Portanto:

$$AE_{\text{sur}}(T) = \frac{5 \min(AT_{\text{sur}}(T), AC_{\text{cont}}(T)) + \max(AT_{\text{sur}}(T), AC_{\text{cont}}(T))}{6}. \quad (8)$$

O componente mais fraco continua recebendo peso 5, preservando o efeito de gargalo elicitado. Na versão inicial, $AC_{\text{cont}} = AC_{\text{original}}$. Na versão refinada, AC_{cont} é obtido pela Equação (6).

Adicionalmente, foi introduzido um parâmetro de suavização $\sigma_{AE} = 0.15$, calibrado para aproximar a forma da distribuição de saída da BN. Esse parâmetro controla a dispersão de uma gaussiana centrada em AE_{sur} e projetada sobre os cinco centróides ordinais $\{0.1, 0.3, 0.5, 0.7, 0.9\}$, produzindo a distribuição de probabilidade prevista pelo surrogate sobre os estados $\{VL, L, M, H, VH\}$.

1.2 Calibração do surrogate em relação à BN

Embora a estrutura funcional do surrogate tenha sido inspirada pela BN e tenha reutilizado seus pesos calibrados como ponto de partida, o modelo surrogate possui natureza analítica e estruturalmente distinta da rede bayesiana. Por essa razão, seus parâmetros foram ajustados empiricamente em função da própria BN, usando-a como *teacher model*, com o objetivo de maximizar a fidelidade da aproximação.

A calibração descrita nesta seção corresponde à derivação original do *surrogate* em relação à BN. O refinamento posterior à validação com a autoridade decisória não realizou uma nova estimação dos pesos (3, 1, 5) ou (5, 1), nem alterou a função MIXMINMAX. Foram modificados dois elementos operacionais: a decomposição independente das contribuições de *Should-have* e *Could-have*, acompanhada do tratamento da redundância de *Must-have*; e a compressão da escala de AC.

Consequentemente, as métricas de fidelidade apresentadas a seguir documentam a versão originalmente calibrada contra a BN. Elas não devem ser interpretadas como uma nova avaliação de fidelidade da versão refinada, cuja finalidade foi corrigir limitações identificadas no uso com equipes reais, preservando a política global de agregação.

Para isso, foi gerado um conjunto de treinamento com 20.930 cenários avaliados pela BN, cobrindo exaustivamente todas as combinações controláveis de evidências técnicas ($5^3=125$ combinações de Dom×Eco×Ling) e colaborativas (210 distribuições distintas de compatibilidade entre 6 pares), totalizando 26.250 cenários divididos em 80% treino e 20% teste por hash determinístico. Para cada cenário, a BN produziu a distribuição-alvo AE_{BN} , enquanto o surrogate produziu a distribuição prevista AE_{sur} via Eq. (7) suavizada por σ_{AE} . A calibração consistiu em otimizar os parâmetros

$$(w_{dom}, w_{eco}, w_{ling}, w_{min}, w_{max}, \sigma_{AE})$$

minimizando o Brier Score médio sobre o conjunto de treino por busca em grade. Os pesos técnicos foram fixados a partir da função WMEAN da BN ($w_{dom} = 3$, $w_{eco} = 1$, $w_{ling} = 5$); os demais foram buscados livremente.

Geração do dataset de calibração. O dataset foi gerado de forma exaustiva e controlada, enumerando todas as combinações possíveis de entradas discretas da BN: $5^3 = 125$ combinações de rótulos Dom×Eco×Ling (cada dimensão em {VL,L,M,H,VH}) cruzadas com as 210 distribuições distintas de compatibilidade para $|\mathcal{P}(T)| = 6$ pares de desenvolvedores (todas as formas de distribuir 6 pares entre 5 faixas). Isso produziu $125 \times 210 = 26.250$ cenários únicos, cada um avaliado pela BN para obter a distribuição-alvo AE_{BN} . A divisão treino/teste foi realizada por hash determinístico com proporção 80/20, resultando em 20.930 cenários de treino e 5.320 de teste.

Procedimento de busca. A busca em grade foi conduzida sobre uma amostra aleatória de 3.000 exemplos do conjunto de treino (estratégia adotada para reduzir o custo computacional da busca, mantendo representatividade). Para cada combinação de $(w_{min}, w_{max}, \sigma_{AE})$ no espaço $\{1, \dots, 5\} \times \{1, \dots, 5\} \times \{0.05, 0.10, 0.15, 0.20, 0.25\}$ (125 combinações no total), calculou-se o Brier Score médio sobre a amostra de treino. Os pesos técnicos foram mantidos fixos em $w_{dom} = 3$, $w_{eco} = 1$, $w_{ling} = 5$, por espelharem diretamente os pesos da função WMEAN da BN. Os parâmetros vencedores foram então avaliados sobre o treino completo (20.930 cenários) e sobre o conjunto de teste (5.320 cenários), sem qualquer reajuste posterior.

A Tabela 1 registra a progressão dos melhores resultados ao longo da busca, ilustrando como o algoritmo refinou os parâmetros iterativamente.

Table 1: Progressão da busca em grade: melhores configurações encontradas em ordem cronológica (avaliadas sobre amostra de 3.000 exemplos de treino).

$w_{\min}$	$w_{\max}$	σ_{AE}	Brier (amostra)	Iteração
1	1	0.05	0.07133	1/125
1	1	0.10	0.03944	2/125
1	1	0.15	0.02896	3/125
1	1	0.20	0.02854	4/125
2	1	0.10	0.02711	27/125
2	1	0.15	0.02046	28/125
3	1	0.15	0.01747	53/125
4	1	0.15	0.01620	78/125
5	1	0.15	0.01560	103/125

Resultados. Os melhores parâmetros encontrados foram:

$$w_{\text{dom}} = 3, \quad w_{\text{eco}} = 1, \quad w_{\text{ling}} = 5, \quad w_{\min} = 5, \quad w_{\max} = 1, \quad \sigma_{AE} = 0.15.$$

No conjunto de treino, a calibração resultou em:

$$\text{Brier}_{\text{train}} = 0.01553, \quad \text{MAE}_{\text{mean,train}} = 0.03827.$$

No conjunto de teste, com 5.320 cenários reservados para holdout, o surrogate obteve:

$$\text{Brier}_{\text{test}} = 0.01557, \quad \text{MAE}_{\text{mean,test}} = 0.03854.$$

A diferença entre treino e teste foi de 0.000047 para o Brier Score e de 0.000270 para o MAE médio. Essas pequenas diferenças não indicam deterioração substancial nos cenários de holdout, embora não devam ser interpretadas como prova de equivalência estatística. Os valores $w_{\min} = 5$ e $w_{\max} = 1$ encontrados pela busca reproduzem exatamente a proporção $[5, 1]$ utilizada pela BN em sua função MIXMINMAX, fornecendo suporte adicional à estrutura funcional adotada.

A análise descritiva do holdout controlado encontrou viés médio assinado ($AE_{\text{sur}} - AE_{\text{BN}} = +0.03794$, mediana do erro absoluto de 0.03194, percentil 95 do erro absoluto de 0.09553 e erro absoluto máximo de 0.14913. Erros assinados positivos ocorreram em 94.8% dos cenários. Assim, embora o Brier Score e o MAE indiquem pequeno erro de aproximação, o surrogate apresenta tendência sistemática de superestimar o escore esperado da BN.

A Tabela 2 consolida os resultados das três fases de avaliação.

Table 2: Resumo comparativo das métricas de fidelidade do surrogate nas três fases de avaliação.

Fase	Brier Score	MAE	n
Treino (calibração)	0.01553	0.03827	20.930
Holdout controlado	0.01557	0.03854	5.320
Equipes reais (end-to-end)	0.03284	0.04956	1.200

1.3 Validação em equipes reais (*end-to-end*)

Além da validação sobre o holdout controlado, o surrogate foi avaliado em condições mais próximas do uso real, utilizando equipes formadas por desenvolvedores de uma base anonimizada e avaliadas sobre os seis projetos-alvo descritos na Tabela 3.

Table 3: Projetos-alvo utilizados na validação *end-to-end*.

ID	Nome	Requisitos principais
P1	Portal Corporativo .NET	Dom: Desktop, Web · Eco: .NET · Ling: C#
P2	App Mobile Híbrido	Dom: Mobile · Eco: Android, iOS/iPadOS · Ling: Kotlin, Swift
P3	Plataforma IoT em Nuvem	Dom: IoT, Cloud · Eco: AWS Lambda · Ling: Python, C++
P4	SaaS Web Analítico	Dom: Web · Eco: MongoDB · Ling: JavaScript
P5	Plataforma Web+Cloud	Dom: Web, Cloud · Eco: React, AWS Lambda, MongoDB · Ling: JS, TS, Python
P6	Hardware Embarcado	Dom: Hardware, Embedded · Eco: PCB · Ling: C

Para isso, foram amostradas aleatoriamente 200 equipes por projeto (semente fixa $s = 42$), totalizando 1.200 cenários de equipes reais. Para cada equipe, o pipeline completo foi executado: extração dos escores contínuos Dom, Eco, Ling via *dimension scoring*; cálculo das proporções de compatibilidade ($p_{VL}, \dots, p_{VH}$) via *PC Transformer*; avaliação pelo surrogate via Eq. (8); e consulta à distribuição-alvo AE_{BN} via *teacher lookup* (tabela pré-computada das avaliações da BN sobre o dataset controlado).

Os resultados obtidos foram:

$$\text{Brier}_{e2e} = 0.03284, \quad \text{MAE}_{\text{mean},e2e} = 0.04956, \quad n = 1.200 \text{ equipes.}$$

A Tabela 4 apresenta a fidelidade end-to-end por projeto-alvo.

Table 4: Fidelidade do surrogate por projeto na validação end-to-end (200 equipes por projeto, tamanho da equipe $k = 4$).

Projeto	Domínio	Brier Score	MAE	Viés médio
P1	Portal Corporativo .NET	0.01582	0.01406	+0.00724
P2	App Mobile Híbrido	0.03845	0.05914	+0.04306
P3	Plataforma IoT em Nuvem	0.03598	0.06044	+0.05370
P4	SaaS Web Analítico	0.03170	0.03696	+0.03118
P5	Plataforma Web+Cloud	0.02215	0.02561	+0.00246
P6	Hardware Embarcado	0.05293	0.10115	+0.09989
Média global		0.03284	0.04956	+0.03959

Considerando todos os cenários end-to-end, a mediana do erro absoluto foi 0.03194, o percentil 95 foi 0.11251 e o maior erro individual foi 0.18748. P1 apresentou os menores erros médios, enquanto P6 apresentou o maior Brier Score (0.05293), o maior MAE (0.10115) e o maior viés médio positivo (+0.09989). O viés médio assinado global de +0.03959 indica que o surrogate também tende a superestimar o escore esperado da BN no cenário end-to-end.

Como esperado, os erros nessa fase são superiores aos do holdout controlado ($\text{Brier}_{\text{test}} = 0.01557$, $\text{MAE}_{\text{test}} = 0.03854$), pois as equipes reais produzem escores contínuos de dimensão fora do grid discreto utilizado no treinamento. Em relação ao holdout, o Brier aumentou aproximadamente 111% e o MAE aproximadamente 29%. Ainda assim, o MAE médio de 0.050 na escala $[0, 1]$ indica que o surrogate erra em média menos de 5 pontos percentuais ao estimar a aptidão de uma equipe real em relação à BN, mantendo fidelidade suficiente para uso como função de avaliação aproximada no AG. O fato de nenhum cenário ter ficado sem correspondência no

teacher lookup (missing = 0) confirma ainda que o dataset controlado cobre adequadamente o espaço de entradas encontrado na prática.

1.4 Eficiência computacional

O custo computacional do surrogate e da rede bayesiana foi avaliado sob quatro condições: avaliação direta de equipes com o surrogate (C1), pipeline completo do AG com o surrogate (C2), avaliação direta de equipes com a BN (C3) e pipeline completo do AG com a BN (C4). O benchmark cobriu cinco projetos-alvo e cinco rodadas por condição e projeto, resultando em 25 medições por condição e 100 medições no total. Cada rodada realizou exatamente 210 avaliações de fitness. Nas condições com AG, isso corresponde a uma população de 10 indivíduos avaliada na inicialização e ao longo de 20 gerações completas. O cache e a parada antecipada foram desativados, e foi realizado aquecimento dos avaliadores antes da medição com `time.perf_counter()`.

Table 5: Tempo de execução dos avaliadores surrogate e rede bayesiana. Os valores representam média $\pm$ desvio-padrão amostral sobre 25 execuções por condição.

Condição	Surrogate (s)	BN (s)	Aceleração
Avaliação direta (sem AG)	0.5713 ± 0.1293	11.2514 ± 1.9015	$19.69\times$
Pipeline completo do AG	0.5493 ± 0.1133	11.9139 ± 1.4116	$21.69\times$

Agrupando as 50 medições de cada avaliador, o tempo médio de execução foi de 0.5603 s para o surrogate e 11.5826 s para a BN. A razão foi de 20.67, de modo que o surrogate foi aproximadamente $20.7\times$ mais rápido que a BN no protocolo controlado do benchmark.

Na avaliação direta, o custo médio foi de aproximadamente 2.721 ms por equipe com o surrogate e 53.578 ms com a BN. No pipeline completo do AG, os valores correspondentes foram 2.616 ms e 56.733 ms por avaliação de fitness. Os tempos totais semelhantes observados com e sem o AG indicam que as chamadas ao avaliador dominam o tempo medido sob esse protocolo fixo. Os intervalos de confiança de 95% para as diferenças médias pareadas C2–C1 e C4–C3 incluíram zero; contudo, nenhum teste de equivalência foi realizado, de modo que esses resultados não devem ser descritos como prova de equivalência estatística. Como os metadados de hardware e do ambiente de software não foram registrados, os tempos absolutos caracterizam o ambiente original de execução, enquanto as razões de aceleração obtidas no mesmo ambiente constituem o resultado comparativo mais apropriado.

2 Plano de validação do surrogate em relação à BN

O benchmark de tempo apresentado acima avalia o custo computacional. As análises descritas a seguir representam validações adicionais necessárias para comparar a preservação do ranking e a qualidade, avaliada pela BN, das soluções retornadas pelos dois modos de execução do AG.

A validação do surrogate AE_{sur} em relação à BN de Team Fit é organizada em duas fases complementares: (i) comparação direta das saídas do surrogate com as saídas da BN, dado o mesmo conjunto de cenários; e (ii) análise do impacto prático do surrogate quando usado como avaliador dentro do AG, em comparação com o uso exclusivo da BN.

2.1 Fase 1 – Surrogate vs BN nos mesmos cenários

1. **Seleção de cenários.** Escolher um conjunto de cenários (T, P) , onde T é uma equipe e P é o projeto-alvo. Esses cenários podem ser provenientes de: (i) conjuntos já usados na calibração/validação da BN; ou (ii) equipes amostradas a partir de execuções do próprio AG.

2. **Extração das *features* comuns.** Para cada cenário (T, P) , calcular:

- os escores técnicos contínuos $Dom, Eco, Ling \in [0, 1]$;
- a distribuição de compatibilidade entre pares, representada por $(p_{VL}, p_L, p_M, p_H, p_{VH})$.

3. **Avaliação com a BN.** Para cada cenário, fixar as evidências na BN e inferir a distribuição:

$$P(AE = \{VL, L, M, H, VH\}).$$

Em seguida, converter essa distribuição em valor esperado:

$$AE_{BN} = \sum_{s \in \{VL, L, M, H, VH\}} p_s \cdot \text{centroide}(s),$$

com centróides $\{0.1, 0.3, 0.5, 0.7, 0.9\}$.

4. **Avaliação com o surrogate.** Usando os mesmos dados de entrada, calcular:

$$\begin{aligned} AT_{\text{sur}} &= \frac{3 Dom + Eco + 5 Ling}{9}, \\ AC_{\text{original}} &= 0.1 p_{VL} + 0.3 p_L + 0.5 p_M + 0.7 p_H + 0.9 p_{VH}, \\ AC_{\text{cont}} &= 0.5 + 0.5 (AC_{\text{original}} - 0.5), \\ AE_{\text{sur}} &= \frac{5 \min(AT_{\text{sur}}, AC_{\text{cont}}) + \max(AT_{\text{sur}}, AC_{\text{cont}})}{6}. \end{aligned}$$

Para reproduzir a avaliação da versão originalmente calibrada contra a BN, utiliza-se $AC_{\text{cont}} = AC_{\text{original}}$. Para reproduzir a versão refinada empregada após a validação, aplica-se a transformação de compressão apresentada acima.

5. **Métricas de fidelidade.** Considerando todos os cenários, calcular:

- Brier Score entre a distribuição prevista pelo surrogate e a distribuição-alvo da BN;
- MAE entre as médias esperadas $E[AE_{\text{sur}}]$ e $E[AE_{BN}]$;
- opcionalmente RMSE;
- correlação de ranking (Spearman ou Kendall) entre os valores produzidos pela BN e pelo surrogate.

6. **Critério de aceitação.** O surrogate é considerado adequado se apresentar baixo erro probabilístico, baixo erro na média esperada e alta preservação do ranking de equipes induzido pela BN.

2.2 Fase 2 – Surrogate dentro do GA vs BN dentro do GA

1. **Definição de dois modos de execução.**

- **Modo A (referência):** o AG usa a BN como função de fitness, isto é, $\text{fitness}(T) = AE_{BN}(T)$;
- **Modo B (surrogate):** o AG usa o surrogate como função de fitness, isto é, $\text{fitness}(T) = AE_{\text{sur}}(T)$, mas o valor final das melhores equipes é sempre reavaliado pela BN.

2. **Execuções replicadas.** Executar ambos os modos com múltiplas sementes, usando a mesma configuração de AG (tamanho da população, número de gerações, p_c , p_m , elitismo, etc.).

3. **Métricas por execução.** Para cada execução, registrar:

- a melhor equipe encontrada;
 - o valor AE_{BN} dessa equipe;
 - o número de avaliações da BN realizadas;
 - o tempo total de execução.
4. **Comparação de qualidade.** Comparar as distribuições do melhor AE_{BN} obtido em cada modo, usando média, mediana, boxplot e, se necessário, testes estatísticos como Wilcoxon.
 5. **Comparação de custo.** Comparar o número médio de avaliações da BN e o tempo total de execução entre os dois modos, verificando se o surrogate reduz o custo computacional sem degradar significativamente a qualidade final das soluções.

2.3 Posicionamento do surrogate em relação à literatura

A abordagem adotada nesta tese difere da arquitetura clássica de *Surrogate-Assisted Evolutionary Algorithms* (SAEAs) descrita por Tong et al. [1]. Nesse trabalho Tong et al. [1], o surrogate atua como filtro auxiliar dentro do laço evolutivo, reduzindo o número de chamadas à função de fitness real, que continua sendo invocada para re-avaliação de parte dos indivíduos. Nesta tese, o surrogate assume um papel distinto: substitui integralmente a BN como avaliador durante a execução do AG, tendo sido calibrado contra ela em fase *offline*. A Figura 2 ilustra essa diferença arquitetural, e a Tabela 6 sistematiza as semelhanças e diferenças.




Figure 2: Compar o arquitetural entre o SAEA cl ssico [1] (esquerda) e a abordagem adotada nesta tese (direita). No SAEA cl ssico, o surrogate filtra candidatos mas a fun o de fitness real   ainda invocada para re-avalia o em cada ciclo evolutivo. Nesta tese, o surrogate substitui integralmente a BN durante o AG: a BN   usada apenas na fase *offline* de calibra o, e nunca   chamada durante a evolu o.

Table 6: Comparação entre o surrogate desta tese e o framework SAEA de Tong et al. [1].

Aspecto	SAEA clássico [1]	Esta tese
Objetivo do surrogate	Reduzir o número de chamadas à função de fitness real	Substituir integralmente a BN como avaliador do AG
Papel da função real no AG	Invocada em todo ciclo para re-avaliação de indivíduos selecionados	Não invocada durante a execução do AG
Quando a função real é usada	Em cada geração, para re-avaliar os melhores candidatos	Apenas na fase <i>offline</i> , para gerar o dataset de calibração
Estratégia de treinamento	Online e incremental (dataset cresce com as re-avaliações do AG)	Offline e exaustiva (26.250 cenários pré-gerados antes do AG)
Gestão do modelo (<i>model management</i>)	Necessária (controle individual ou por geração; critério de re-avaliação)	Não necessária (surrogate é o único avaliador)
Tipo de surrogate (taxonomia Tong et al.)	RBF, kNN-R, RankSVM, SVC (modelos genéricos de ML)	Fórmula analítica fechada inspirada na estrutura da BN (WMEAN + MIXMINMAX)
Risco de falso ótimo	Presente; mitigado pela re-avaliação periódica pela função real	Presente; mitigado pela alta fidelidade de calibração (MAE < 0.05)
<i>Pontos em comum</i>		
Motivação	Reduzir custo computacional de avaliações caras em AGs	
Relação com a função real	Surrogate aprende a aproximar o comportamento da função real a partir de dados por ela gerados	
Métricas de fidelidade	Avaliação por Brier Score (qualidade da distribuição) e MAE (erro na média esperada)	
Integração ao AG	O surrogate é chamado no passo de avaliação de fitness do laço evolutivo	

References

- [1] Hao Tong, Changwu Huang, Leandro L. Minku, and Xin Yao. Surrogate models in evolutionary single-objective optimization: A new taxonomy and experimental study. *Information Sciences*, 562:414–437, 2021. ISSN 0020-0255. doi: <https://doi.org/10.1016/j.ins.2021.03.002>. URL <https://www.sciencedirect.com/science/article/pii/S0020025521002395>.